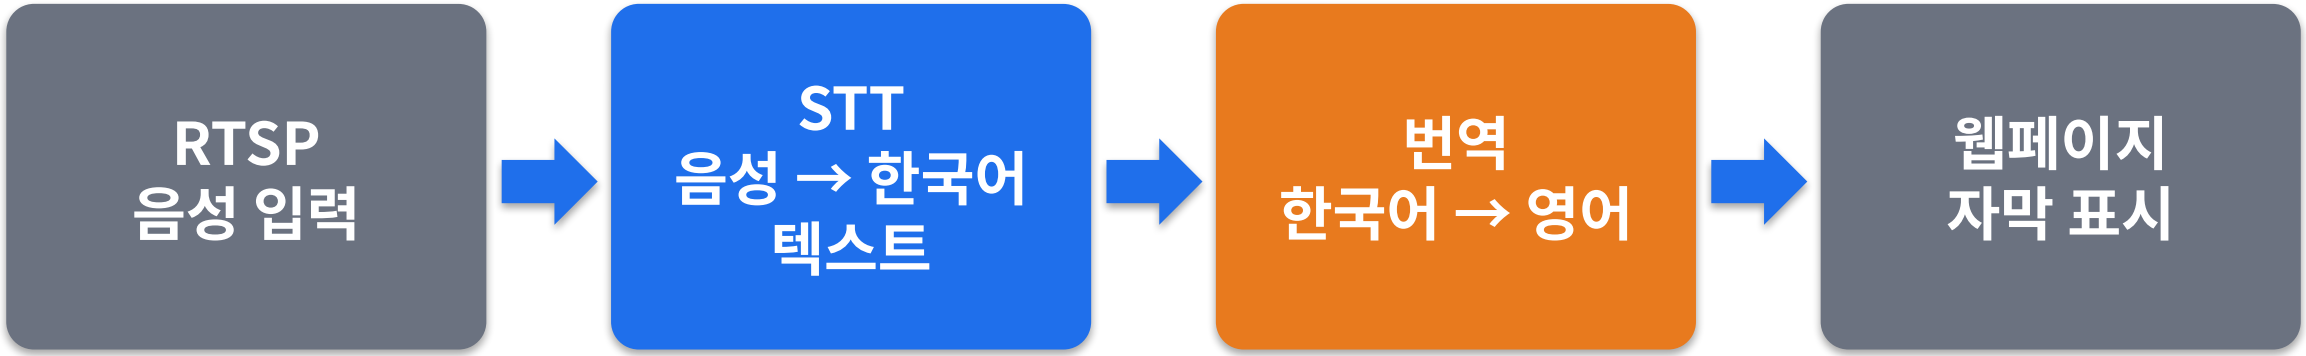
ODROID-M2 로 만드는 로컬 실시간 번역

음성 → 한국어 텍스트 → 영어 , 인터넷 없이 보드 안에서

NPU 워크샵 (입문)

이런 걸 만들려고 합니다



전부 보드 안에서 동작 (클라우드 API 없음)

한국어 원문과 영어 번역을 웹에서 함께 확인

ODROID-M2 는 어떤 보드인가

CPU	NPU	메모리
8 코어 빅 4 개 (A76, 2.2GHz) 리틀 4 개 (A55, 1.8GHz)	3 코어 , 최대 6 TOPS (이론상 최대치 , INT8) RKLLM/RKNN 으로 사용	RAM 8GB CPU 와 NPU 가 함께 사용

사용 환경 : Ubuntu 26.04, 커널 6.1 (Rockchip), NPU 드라이버 0.9.8

NPU 를 쓰려면 : 변환 → 복사 → 실행

① x86 PC

RKLLM-Toolkit 으로
모델 변환
(.rkllm 파일 생성)

② 복사

scp 로 파일을
보드에 복사

③ 보드에서 실행

librkllmrt.so 가
NPU 에 모델을 올리고
추론

	모델 종류	PC 도구	결과 파일
RKLLM	LLM (번역 , 대화)	rkllm-toolkit	.rkllm
RKNN	비전 (YOLO 등)	rknn-toolkit2	.rknn

RKLLM 함수 ① 모델 올리고 실행하기

함수	하는 일	주요 입력	결과
rkllm_createDefaultParam()	기본 설정 만들기	-	설정값 (아래 참고)
rkllm_init(handle, param, callback)	모델을 NPU 에 올림	설정값 , 결과를 받을 콜백	0 이면 성공
rkllm_run(handle, input, infer_param, userdata)	질문을 넣고 생성 시작 (끝날 때까지 기다림)	텍스트 프롬프트	글자가 생길 때마다 콜백 호출

설정값의 주요 항목

model_path	모델 (.rkllm) 파일 경로	**top_k / top_p / temperature**	글자를 고르는 방식
max_context_len / max_new_tokens	기억할 최대 길이 / 만들 최대 길이	**enabled_cpus_mask**	RKLLM 이 쓸 CPU 코어 지정 (extend_param 안)

RKLLM 함수 ② 결과 받고 정리하기

함수	하는 일	주요 입력	결과
callback(result, userdata, state)	생성된 글자를 받는 곳	-	result.text 에 글자 , state 로 진행 상태
rkllm_destroy(handle)	모델 해제	handle	0 이면 성공

콜백 state 값

state	의미
0	글자 도착 (생성 중)
1	글자 완성 대기
2	끝
3	오류

보조 함수

함수	하는 일
rkllm_run_async	기다리지 않고 실행
rkllm_abort	생성 중단
rkllm_clear_kv_cache	대화 기록 지우기
rkllm_set_chat_template	프롬프트 형식 지정

흐름 : init → run → (콜백이 여러 번) → destroy

예제 코드

① 라이브러리 직접 호출 (흐름만 , 구조체 정의 생략)

```
lib = ctypes.CDLL("lib/librkllmrt.so")

#  설정 → 모델을 NPU 에 올림
param = RKLLMParam()
param.model_path = b"model.rkllm"
param.max_context_len = 4096
param.top_k = 1
lib.rkllm_init(byref(handle), byref(param),
               byref(callback))

#  글자가 생길 때마다 불리는 콜백
def on_result(result, userdata, state):
    if state == 0:   #  생성 중
        text += result.contents.text.decode()
    if state == 2:   #  끝
        print(text)
    return 0

#  질문 넣기 ( 끝날 때까지 기다림 )
inp = RKLLMInput(); inp.input_type = 0   #  텍스트
inp.role = b"user"; inp.prompt_input = b" 안녕 "
lib.rkllm_run(handle, byref(inp), byref(infer), None)
lib.rkllm_destroy(handle)
```

② 서버로 띄워서 HTTP 로 사용 (그대로 실행)

```
import json, urllib.request

prompt = ("Translate Korean to English. "
          "Output only the translation.\n\n"
          "Korean:  안녕하세요 \nEnglish:")

req = urllib.request.Request(
    "http://< 보드 IP>:8080/v1/chat/completions",
    json.dumps({"model": "x", "messages": [
        {"role": "user", "content": prompt}
    ]}).encode(),
    {"Content-Type": "application/json"})

res = json.load(urllib.request.urlopen(req))
print(res["choices"][0]["message"]["content"])
```

전체 구조체 정의 : rknn-llm/examples/rkllm_server_demo/rkllm_server/flask_server.py | 서버 실행 : ./scripts/run_rkllm_server.sh <model.rkllm>

이런 방법도 있습니다 : 작업 나누기

전부 NPU	전부 CPU	작업별로 나누기
모델을 NPU 에 올려 처리 구성이 단순	llama.cpp, faster-whisper 등 기존 도구를 그대로 사용 고를 수 있는 모델이 많음	예 : STT 는 CPU, 번역은 NPU NPU 를 쓰는 작업만큼 CPU 를 비움

이미 쓰이는 예 : 멀티모달 모델은 비전 인코더를 RKNN, 언어 모델을 RKLLM 으로 나눠 NPU 에서 실행
YOLO 같은 비전 모델은 후처리를 CPU 가 처리

※ 우리 구성은 아직 확정 전입니다 . 테스트로 정합니다 .

앞으로 할 일

할 일

① STT 모델 후보 찾기

② 번역 모델 후보 찾기

③ 모델만 바꿔 테스트하는 기반 코드

모델 고르는 기준

메모리	남는 RAM 안에 들어가는가
속도	목표 예 : 번역 15 토큰 / 초 , STT 실시간의 절반
품질	한국어 샘플 문장으로 직접 확인
변환 지원	RKLLM 지원 모델인가

```
#  기반 코드 설정 예시 ( 제작 예정 )
SOURCE    = "test.wav"  #  또는 "rtsp://..."
STT_MODEL = "small"
TRANSLATE = "http:// 보드 :8080/v1/chat/completions"
```